IAE Nantes
Économie & Management
Pôle Sociétés

Nantes Université

Dossier Régressions pénalisées et sélection de variables

M2 ECAP

Indice de la production industrielle au Royaume-Uni (IOP_PROD)

Réalisé par :

Diane ANATO et Patrice KOLIE

Année universitaire 2026 – 2027

Sommaire :

I. Introduction 3
II. Analyse exploratoire et descriptive 4
A. Analyse des valeurs manquantes 4
1. Visualisation des valeurs manquantes 4
B. Graphique de l'évolution de l'indice de la production industrielle du Royaume-Uni (1998-2025) 5
1. Les outliers 6
2. Tests de stationnarité sur IOP_PROD 7
3. Tests de saisonnalité sur IOP_PROD 7
C. Statistiques descriptives de la variable à expliquer (IOP_PROD) 8
1. Boxplot de la variable à expliquer (IOP_PROD) 9
D. Corrélations 10
1. Corrélation entre les variables explicatives et la variable expliquer (IOP_PROD) 10
2. Corrélation entre les variables explicatives 11
III. Sélection de variables 12
A. Choix et interprétation du paramètre de régularisation 12
B. Les variables retenues 13
C. Tableau des coefficients 14
IV. Conclusion 16

I. Introduction

La production industrielle est l'un des indicateurs les plus suivis de la conjoncture. Publiée chaque mois, bien avant les comptes trimestriels du PIB, elle mesure rapidement l'activité des secteurs les plus sensibles au cycle économique. Au Royaume-Uni, elle a connu depuis la fin des années 1990 une longue stagnation, interrompue par des chocs majeurs comme la crise financière de 2008 ou l'effondrement du printemps 2020 lié à la pandémie de Covid-19. Savoir quels indicateurs accompagnent ses variations est donc précieux pour le suivi de l'économie.

Les bases de données macroéconomiques actuelles rassemblent des dizaines de séries sur le travail, la production, les échanges, les prix, le crédit ou les marchés financiers. Cette richesse pose cependant un problème statistique : lorsque les variables explicatives sont nombreuses et fortement corrélées entre elles, la régression linéaire classique devient instable et difficile à interpréter. Les régressions pénalisées répondent à cette difficulté en contraignant la taille des coefficients, et certaines d'entre elles sélectionnent automatiquement les variables les plus informatives. Ce dossier applique ces méthodes à la croissance mensuelle de la production industrielle britannique (IOP_PROD), à partir de la base balanced_uk_md, issue de la base UK-MD de Goulet Coulombe, Marcellino et Stevanović (2021). Celle-ci compte 113 variables et 338 observations mensuelles, de janvier 1998 à février 2026, et ses séries sont déjà corrigées des variations saisonnières et transformées pour être stationnaires.

La première partie présente l'analyse exploratoire : traitement des valeurs manquantes, vérification graphique de la stationnarité de la variable à expliquer, statistiques descriptives, détection des points atypiques et étude des corrélations, qui révèle une colinéarité généralisée entre les variables explicatives. La seconde partie met en œuvre plusieurs méthodes de régression pénalisée : Ridge, Lasso, Elastic-Net (à α fixé et par recherche sur grille), adaptive Lasso (à poids Ridge et à poids Lasso) et SCAD. Toutes sont calibrées par validation croisée à 10 blocs, en retenant le paramètre de pénalisation le plus élevé dont l'erreur reste à moins d'un écart-type de l'erreur minimale, ce qui privilégie des modèles plus parcimonieux. Les méthodes sont ensuite comparées selon leur performance hors échantillon et leur parcimonie, et confrontées à une régression par moindres carrés ordinaires.

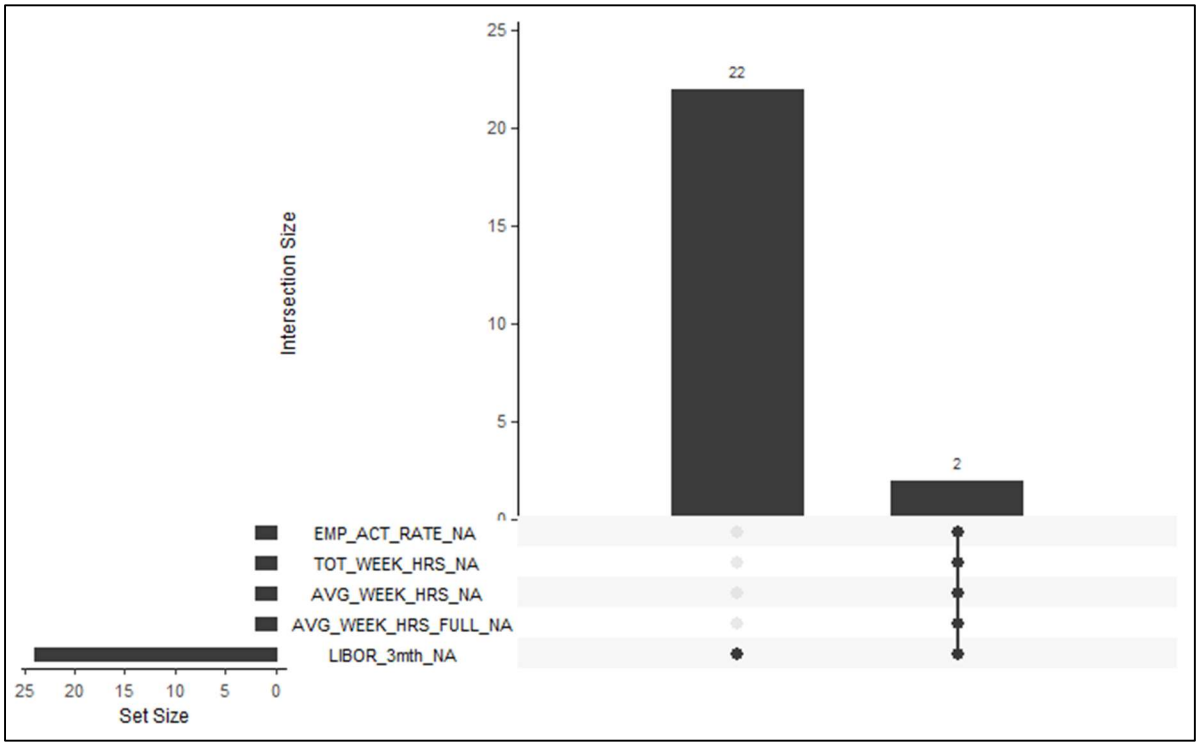
II. Analyse exploratoire et descriptive

Avant de procéder à la sélection des variables, cette première partie est consacrée à l'exploration des données afin de vérifier leur exploitabilité et de mieux comprendre leur structure. Nous commençons par examiner les valeurs manquantes au sein du jeu de données. Nous étudions ensuite la variable à expliquer, l'indice de la production industrielle (*IOP_PROD*), en vérifiant sa stationnarité et l'absence de saisonnalité, bien que le jeu de données soit supposé stationnaire au préalable. Enfin, nous analysons les corrélations entre les variables explicatives et la variable à expliquer, ainsi que les corrélations entre les variables explicatives elles-mêmes.

A. Analyse des valeurs manquantes

La base de départ comporte 338 observations mensuelles ,99 variables explicatives dont une variable à expliquer (*IOP_PROD)*. Avant toute transformation, nous avons recensé les valeurs manquantes par variable puis par observation

1. Visualisation des valeurs manquantes



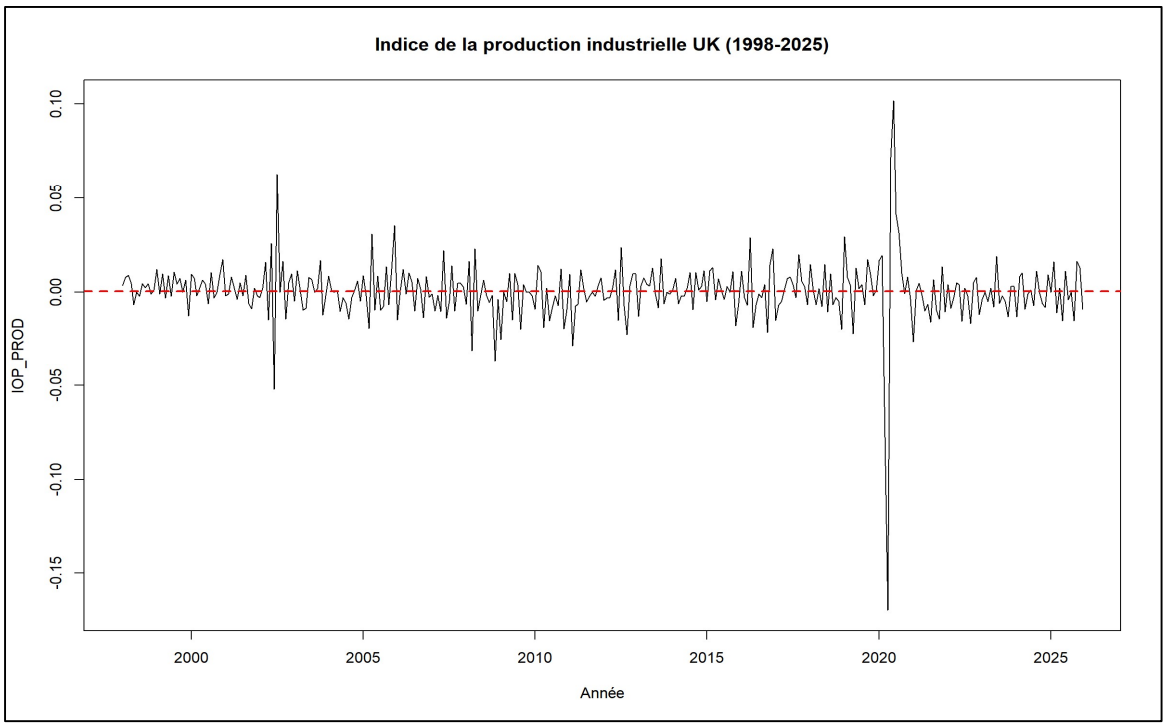
Source : Auteurs à partir des données de la base balanced_uk_md sous R

L'analyse visuelle confirme une concentration de l'information manquante sur un nombre très restreint d'éléments. La barre principale du graphique met en évidence un bloc majeur de 24 valeurs manquantes isolées sur une seule variable, le taux LIBOR à trois mois (LIBOR_3mth). Cette absence de données s'explique par l'arrêt de la publication du taux LIBOR à la fin de l'année 2021. Par ailleurs, deux observations présentent des valeurs manquantes simultanément dans ces cinq variables. Elles correspondent aux deux dernières périodes de l'échantillon.

Face à ce constat, un arbitrage a été mené pour maximiser la conservation des observations, critère essentiel à la robustesse d'une étude en séries temporelles. Plutôt que de sacrifier 24 lignes complètes pour maintenir le taux LIBOR, le choix a été fait de supprimer la variable. À l'inverse, les deux dernières lignes de la base se sont révélées trop incomplètes pour être imputées de manière fiable et ont été retirées de l'échantillon. Situées en extrême fin de période, leur retrait ne perturbe pas la dynamique chronologique de l'étude.

En complément, plusieurs ajustements structurels ont été opérés : la colonne technique d'indexation (X) a été écartée, la variable temporelle a été convertie au format date et la base a été ordonnée chronologiquement. Enfin, afin d'éviter tout biais mécanique, les onze variables de production industrielle sectorielle ont été exclues pour ne conserver que l'indice général (IOP_PROD). À l'issue de ces étapes, la base finale est exempte de toute valeur manquante et s'étend de manière continue sur 336 observations mensuelles, de janvier 1998 à décembre 2025.

B. Graphique de l'évolution de l'indice de la production industrielle du Royaume-Uni (1998-2025)

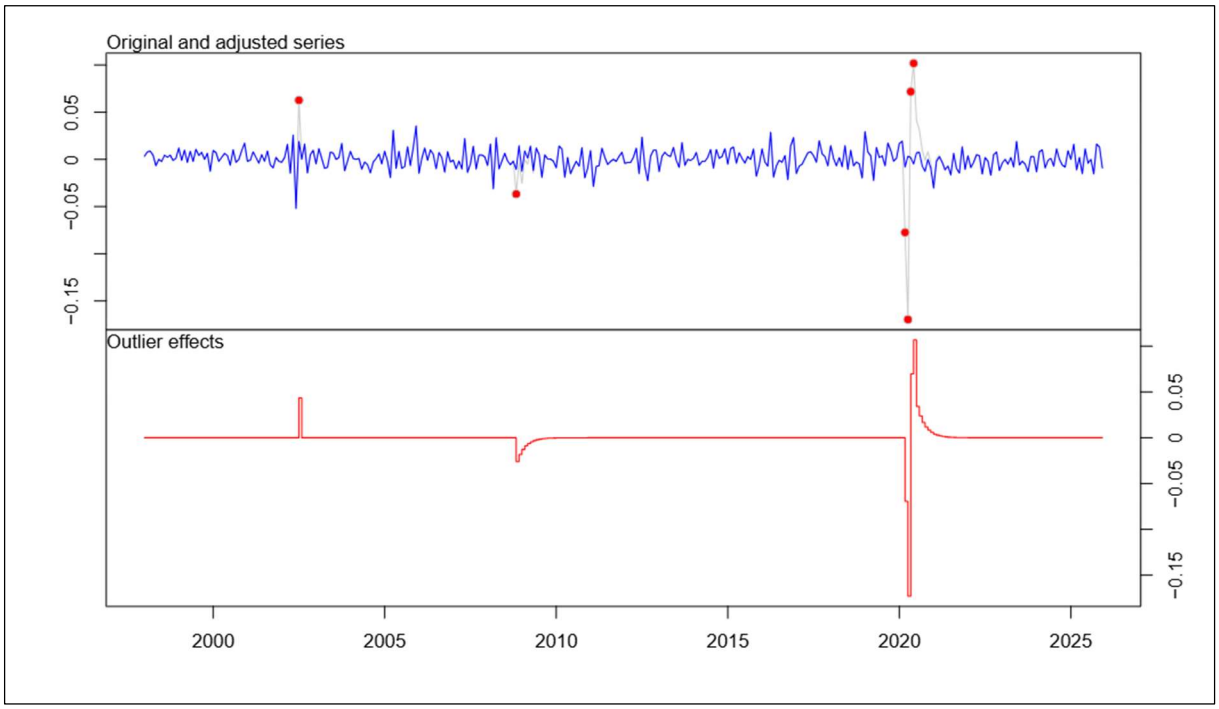


Source : Auteurs à partir des données de la base balanced_uk_md sous R

La série de la production industrielle britannique (IOP_PROD) présente un profil stationnaire sur la période 1998-2025 : des oscillations mensuelles régulières autour d'une moyenne quasi nulle, sans tendance ni rupture de niveau durable. Trois épisodes s'en détachent. À l'été 2002, un choc positif isolé rompt brièvement la stabilité de la série, conséquence documentée des jours fériés supplémentaires du Jubilé d'or de la reine Elizabeth II en juin 2002, qui a interrompu l'activité avant un rattrapage en juillet. À partir de fin 2008, la production s'affaisse de manière prolongée, marquant l'entrée de l'économie britannique dans la Grande Récession consécutive à la crise financière mondiale. Enfin, l'année 2020 concentre des fluctuations d'une amplitude inédite : effondrement vertical de l'activité au printemps lors du premier confinement lié au Covid-19, suivi d'un rebond tout aussi violent à la réouverture. Dès 2021, la série retrouve un

comportement conforme à ses propriétés de long terme, confirmant le caractère transitoire de cette crise.

1. Les outliers



Type d'Outlier	Obs	Date du Choc	Coefficient	Statistique de Student
AO	55	07/2002	0.043571	4.770378
TC	131	11/2008	-0.026076	-4.831562
TC	267	03/2020	-0.069314	-6.937268
AO	268	04/2020	-0.124390	-8.650491
TC	269	05/2020	0.103807	11.369935
AO	270	06/2020	0.057854	4.285714

Source : Auteurs à partir des données de la base balanced_uk_md sous R

La détection automatique des points atypiques (méthode tso) confirme statistiquement ces observations en identifiant six outliers hautement significatifs, dont les statistiques de Student ($|t| > 4$) dépassent largement le seuil critique. Le graphique distingue la série originale de la série ajustée des effets d'outliers, et permet de visualiser l'empreinte de chaque événement. L'algorithme segmente ces chocs selon leur persistance : les Additive Outliers (AO) modélisent des anomalies impulsionnelles et isolées, tandis que les Temporary Changes (TC) décrivent des perturbations dont l'impact se dissipe progressivement. En juillet 2002, un AO positif unique (beta = +0,0436) traduit le surcroît d'activité ponctuel du rattrapage post-Jubilé, sans effet le mois suivant. À l'inverse, la crise financière de novembre 2008 est captée par un TC négatif

(beta = −0,0261) : la courbe des effets montre une baisse soudaine suivie d'une convalescence lente, à l'image de la destruction durable de capacités et de l'effondrement de la demande de l'époque. L'année 2020 concentre enfin quatre outliers consécutifs de mars à juin, trajectoire non linéaire de la crise sanitaire : TC négatif en mars (beta = −0,0693) correspondant aux premières restrictions, AO négatif historique en avril (beta = −0,1244) au cœur du confinement, puis TC positif massif en mai (beta = +0,1038) et AO positif en juin (beta = +0,0579) pour la reprise. Ces six observations ne sont pas des erreurs de mesure mais de l'information économique : elles sont conservées, et la série ajustée ne sert qu'à l'illustration graphique.

2. Tests de stationnarité sur IOP_PROD

Test	H0	Statistique	p-value	Conclusion
ADF	Racine unitaire (non stationnarité)	-9,234	$< 0,01$	Rejet de H0
KPSS	Stationnarité en niveau	0,154	$> 0,10$	Non-rejet de H0

3. Tests de saisonnalité sur IOP_PROD

Test	H0	Statistique	p-value	Conclusion
QS	Pas d'autocorrélation saisonnière	0	1	H0 non rejeté
Kruskal-Wallis	Mêmes distributions pour tous les mois	5,82	0,885	H0 non rejeté
isSeasonal()	Pas de saisonnalité	-	-	FALSE

Les tests confirment la stationnarité en niveau de la série. Le test ADF rejette l'hypothèse de racine unitaire (statistique de −9,234, p-value < 0,01) tandis que le test KPSS, dont l'hypothèse nulle est la stationnarité, ne la rejette pas (statistique de 0,154, p-value > 0,10). Cette convergence entre deux tests aux hypothèses opposées valide l'utilisation de la série telle quelle, sans différenciation. Les tests de saisonnalité vont dans le même sens : QS (p-value = 1) et Kruskal-Wallis (p-value = 0,885) ne rejettent pas l'absence de dynamique mensuelle, la fonction isSeasonal() renvoie FALSE, et les indicateurs de différenciation optimale sont nuls (ndiffs() = 0, nsdiffs() = 0). Ce résultat est attendu, la base source balanced_uk_md étant déjà corrigée des variations saisonnières en amont.

C. Statistiques descriptives de la variable à expliquer (IOP_PROD)

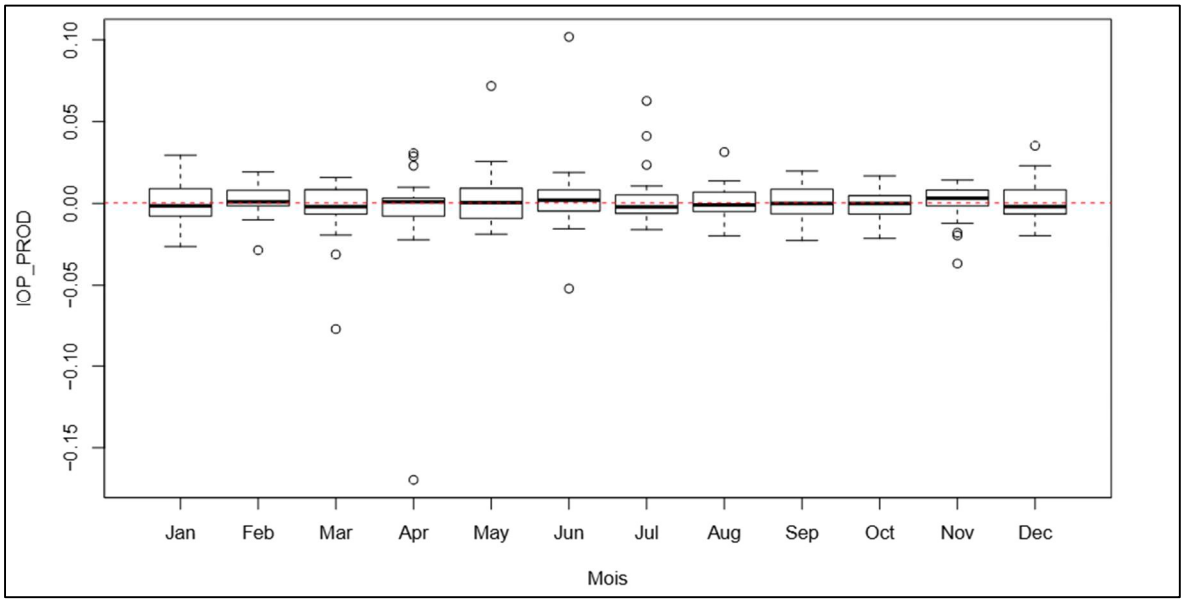
Statistique	IOP_PROD
Obs	336
Moyenne	0.000336
Ecart-Type	0.016871
Médiane	0.000000
Variance	0.000285
Minimum	-0.169645
Maximum	0.101783
Skewness	-2.349214
Kurtosis	35.367469

Le tableau des statistiques descriptives de IOP_PROD (336 observations) confirme numériquement le comportement observé graphiquement. La moyenne (0,000336) et la médiane (0) quasi nulles attestent du centrage de la série. En revanche, les coefficients de forme s'écartent fortement d'une loi normale : l'asymétrie négative (skewness de −2,35) montre que les contractions de l'activité sont plus violentes que ses expansions, et l'aplatissement exceptionnel (kurtosis de 35,37) traduit une distribution leptokurtique. Cette structure s'explique par la coexistence d'une routine mensuelle stable et de chocs exogènes rares, matérialisés par un minimum de −16,96 % (confinement d'avril 2020) et un maximum de +10,18 % (rebond post-Covid).

Le boxplot mensuel confirme visuellement l'absence de saisonnalité tout en localisant les grands chocs. Les douze distributions affichent une géométrie quasi identique, avec une dispersion homogène et une médiane systématiquement alignée sur la ligne de variation nulle. L'intérêt du graphique réside dans ses valeurs atypiques isolées, qui portent la mémoire des crises : avril écrase l'historique avec le minimum absolu de la série (confinement de 2020), tandis que mai, juin et juillet affichent les extrêmes supérieurs (rebonds post-Covid et rattrapage du Jubilé de 2002). Les points bas de mars et novembre rappellent les entrées en récession, notamment 2008. Si la routine industrielle est stable d'un mois à l'autre, ce sont les queues de distribution mensuelles qui portent les ruptures macroéconomiques.

Sur le plan méthodologique, cette non-normalité a une conséquence directe pour la suite : les mesures d'association linéaires classiques étant sensibles aux observations extrêmes, les corrélations de la section suivante sont calculées avec le coefficient de Spearman plutôt qu'avec celui de Pearson. Les points atypiques eux-mêmes sont conservés, car ils traduisent des événements économiques réels dont l'information fait partie de la relation à estimer.

1. Boxplot de la variable à expliquer (IOP_PROD)

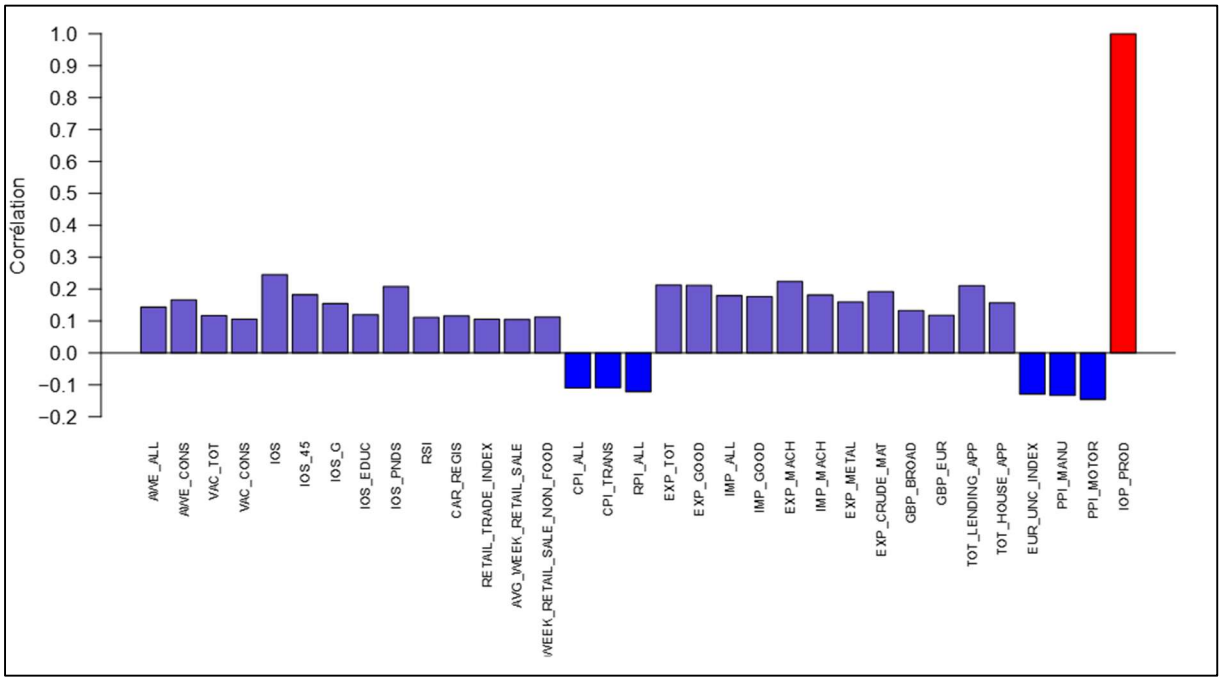


Source : Auteurs à partir des données de la base balanced_uk_md sous R

Le boxplot mensuel confirme visuellement l'absence de saisonnalité tout en localisant les grands chocs de l'économie britannique. Les douze distributions affichent une géométrie quasi identique, avec une dispersion homogène et une médiane systématiquement alignée sur la ligne de variation nulle (0,00). L'intérêt du graphique réside dans ses valeurs atypiques isolées, qui portent la mémoire des crises : avril écrase l'historique avec le minimum absolu de la série (confinement d'avril 2020), tandis que mai, juin et juillet affichent des extrêmes supérieurs qui captent les rebonds de réouverture post-Covid et le rattrapage industriel consécutif au Jubilé d'or de 2002. Les points bas isolés de mars et novembre rappellent enfin les entrées en récession, notamment lors de la crise financière de 2008. Si la routine industrielle est stable d'un mois à l'autre, ce sont les queues de distribution mensuelles qui portent les ruptures macroéconomiques majeures du Royaume-Uni.

D. Corrélations

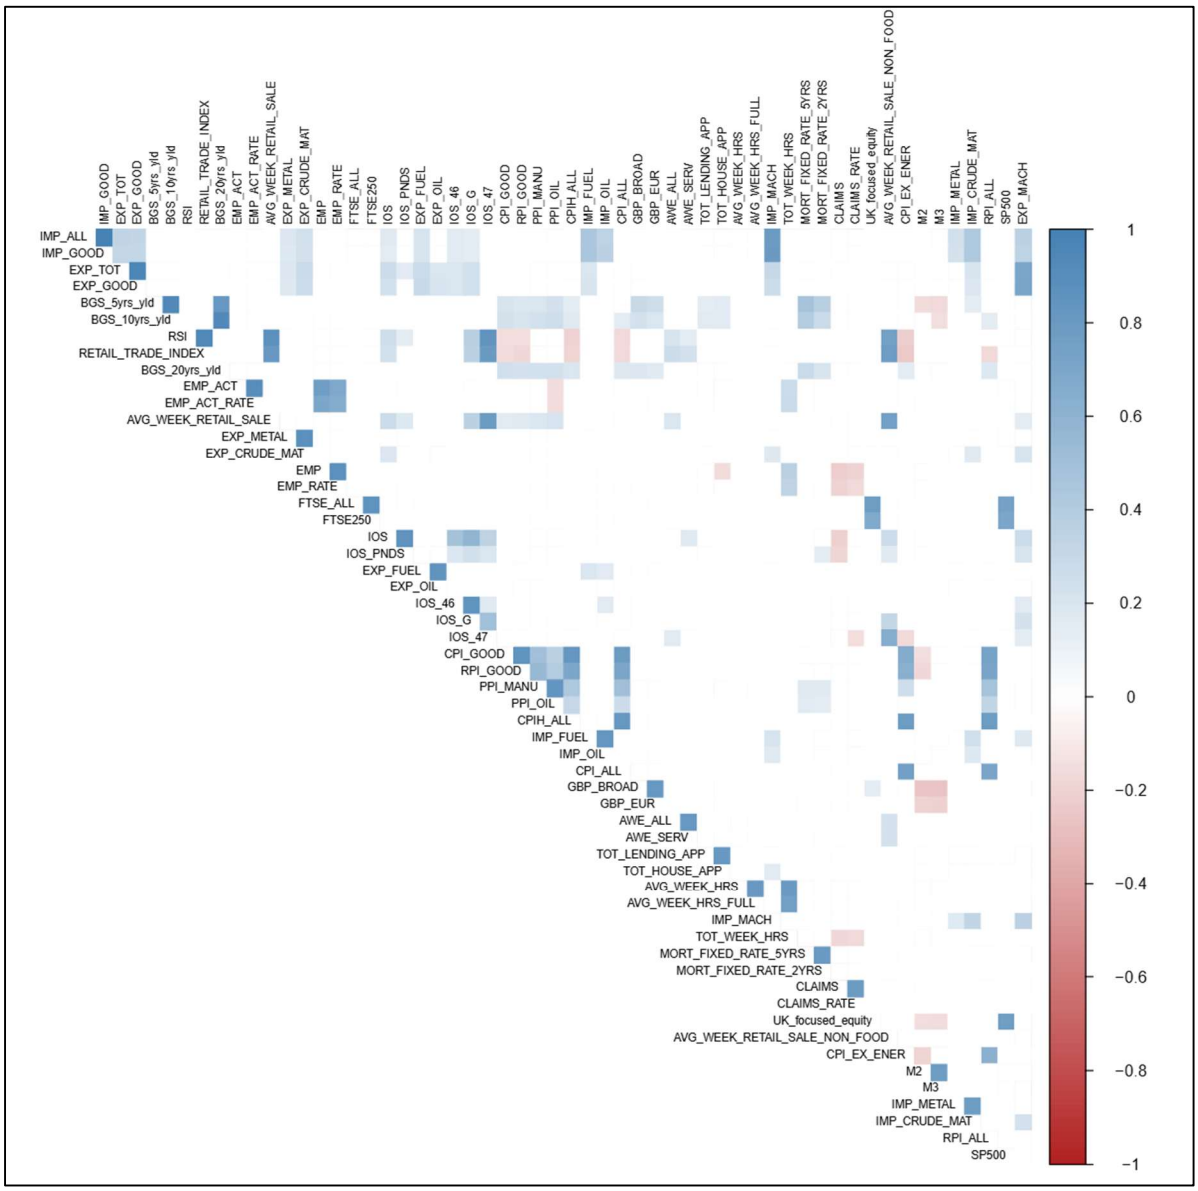
1. Corrélation entre les variables explicatives et la variable expliquer (IOP_PROD)



Source : Auteurs à partir des données de la base balanced_uk_md sous R

Pour identifier les déterminants potentiels de la production industrielle britannique (IOP_PROD) de manière robuste aux observations extrêmes, le coefficient de corrélation de Spearman a été calculé sur l'ensemble de la base. Avec un seuil de $|\rho| \geq 0{,}10$, 32 variables explicatives se dégagent sur les 98 initiales, même si les liaisons individuelles restent structurellement modestes : l'indicateur d'opinion des services (IOS) culmine en tête à 0,245, soit seulement 6 % de variance partagée. Sur le plan macroéconomique, les 26 corrélations positives révèlent une dynamique tirée par le commerce extérieur (exportations de machines EXP_MACH à 0,224, exportations totales EXP_TOT à 0,212, importations totales IMP_ALL à 0,180), suivie de près par les variables de crédit (TOT_LENDING_APP à 0,211), le climat des affaires des services (IOS_PNDS à 0,208) et, dans une moindre mesure, les indicateurs du marché du travail (AWE_CONS) et de la consommation (CAR_REGIS). À l'inverse, les 6 corrélations négatives, comprises entre −0,11 et −0,146, se concentrent sur les indices de prix à la production et à la consommation (PPI_MOTOR à −0,146, PPI_MANU à −0,133) et sur l'incertitude économique (EUR_UNC_INDEX à −0,129), configuration cohérente avec un impact récessif des chocs de coûts et de l'incertitude. Ces liaisons marginales modestes ne préjugent en rien de l'apport des variables une fois considérées conjointement : c'est précisément ce que la partie suivante explore avec les régressions pénalisées.

2. Corrélation entre les variables explicatives



Source : Auteurs à partir des données de la base balanced_uk_md sous R

L'analyse de la matrice des corrélations croisées, restreinte aux liaisons fortes ($|\rho| \geq 0{,}70$), révèle une structure de forte interdépendance qui touche près de la moitié de la base (52 paires, toutes positives, impliquant 45 variables distinctes), un cas critique de quasi-colinéarité. Cette densité de corrélations, particulièrement visible dans les blocs intenses de la matrice graphique, traduit des redondances à la fois comptables (IMP_ALL et IMP_GOOD à 0,987), financières (BGS_5yrs_yld et BGS_10yrs_yld à 0,940) et d'activité commerciale (RSI et RETAIL_TRADE_INDEX à 0,936). Sur le plan économétrique, cette configuration rend la matrice X'X quasi singulière : la variance des estimateurs MCO explose et leurs coefficients deviennent instables, comme le confirmera le tableau des coefficients de la partie II. Cette

configuration légitime le recours aux régressions pénalisées dans la partie suivante, appliquées à l'ensemble des 98 variables explicatives.

III. Sélection de variables

A. Choix et interprétation du paramètre de régularisation

Toutes les méthodes ont été estimées sur les mêmes données, soit 98 variables explicatives centrées-réduites et 336 observations mensuelles. Pour chacune, le paramètre de régularisation λ a été choisi par validation croisée à 10 plis. Le modèle final est estimé au λ_{1se}, c'est-à-dire la valeur la plus élevée de λ dont l'erreur de validation croisée reste à moins d'un écart-type de l'erreur minimale.

Afin d'illustrer l'effet de λ, on considère un cas simplifié dans lequel les variables explicatives sont centrées-réduites et non corrélées entre elles. Dans ce cadre, le coefficient estimé sans pénalisation correspond à la corrélation entre la variable explicative et la variable à expliquer (y). Chaque méthode applique alors un mécanisme de régularisation spécifique.

- **Ridge ($\lambda = 5{,}214$)** : la pénalisation L2 réduit chaque coefficient en le divisant par $1 + \lambda$, soit environ 6,214. Les coefficients sont donc fortement rapprochés de zéro, sans être annulés.
- **Lasso ($\lambda = 0{,}1831$)** : la pénalisation L1 applique un seuil de 0,1831. Les coefficients dont la valeur absolue est inférieure à ce seuil sont annulés, tandis que les autres sont réduits de 0,1831 en valeur absolue.
- **Elastic Net (α, λ)** : les pénalités L1 et L2 se combinent. La composante L1 applique un seuil égal à $\alpha \times \lambda$, puis la composante L2 réduit davantage les coefficients en les divisant par $1 + (1 - \alpha) \times \lambda$.
- **Adaptive Lasso ($\lambda = 0{,}3268$ avec les poids Ridge et $\lambda = 1{,}1472$ avec les poids Lasso)** : le principe est similaire à celui du Lasso, mais le seuil varie selon les variables. Il correspond à $\lambda \times w_j$, où w_j représente le poids attribué à chaque variable. Les variables les plus importantes sont ainsi moins pénalisées.
- **SCAD ($\lambda = 0{,}2365$; $a = 3{,}7$)** : la pénalisation s'applique en trois zones. Pour les coefficients inférieurs à λ, elle fonctionne comme celle du Lasso. Entre λ et $a \times \lambda$ (soit environ 0,875), son intensité diminue progressivement. Au-delà de ce seuil, la pénalisation devient nulle, ce qui permet de préserver les coefficients les plus élevés.

Deux variantes ont été estimées pour Elastic Net : une première avec α fixé à 0,5 et une seconde où α est déterminé par recherche sur grille. Pour Adaptive Lasso, deux estimations initiales ont été utilisées pour calculer les poids : Ridge et Lasso.

Variables	Ridge	Lasso	Elastic-Net (Fixed 0.5)	Elastic-Net (gride search)	aLasso (Poids Ridge)	aLasso (Poids Lasso)	Scad
Lambda	5.2140	0.1831	0.3199	0.1831	0.3268	1.1472	0.2365
Nb de variables	98	6	10	8	2	2	1

Source : Auteurs à partir des données de la base balanced_uk_md sous R

Le tableau fait apparaître trois comportements. Le Ridge conserve les 98 variables, avec des coefficients tous compris entre 0,02 et 0,04 en valeur absolue. À l'opposé, le SCAD ne garde qu'une variable et les adaptive Lasso deux. Entre les deux, le Lasso en garde 6 et les Elastic-Net 10 et 8. Les valeurs de λ ne se comparent pas d'une colonne à l'autre, chaque méthode les interprétant à sa manière. Pour le grid search, $\alpha = 0{,}9$ a été retenu.

Le critère retenu pour comparer les performances des modèles est l'erreur de validation croisée, qui mesure leur capacité à prédire des observations non utilisées lors de l'estimation. Une erreur plus faible indique une meilleure performance prédictive hors échantillon.

Variables	Ridge	Lasso	Elastic-Net (Fixed 0.5)	Elastic-Net (gride search)	aLasso (Poids Ridge)	aLasso (Poids Lasso)	Scad
cv_mse	0.5517	0.5221	0.5366	0.5085	0.4974	0.4764	0.5659
R2	0.5562	0.5290	0.5383	0.5400	0.5310	0.5397	0.4870

Source : Auteurs à partir des données de la base balanced_uk_md sous R

Les adaptive Lasso obtiennent les plus faibles erreurs de validation croisée (0,476 avec les poids issus du Lasso, 0,497 avec ceux du Ridge), devant l'Elastic-Net par grid search (0,509), le Lasso (0,522), l'Elastic-Net à $\alpha = 0{,}5$ (0,537), le Ridge (0,552) et le SCAD (0,566). Le contraste le plus parlant oppose le Ridge aux adaptive Lasso : avec 98 variables, le Ridge fait moins bien qu'un modèle à 2 variables. Les 96 variables secondaires n'apportent donc rien en prédiction, elles ajoutent du bruit. À l'inverse, la variable unique du SCAD ne suffit pas. Le R^2 in-sample classe le Ridge en tête, mais il récompense mécaniquement les modèles les moins parcimonieux et ne dit rien de la capacité à généraliser : c'est pourquoi la comparaison repose sur l'erreur de validation croisée, qui évalue la prédiction sur des observations non utilisées à l'estimation.

Cette configuration légitime le recours aux régressions pénalisées dans la partie suivante : elles permettent d'estimer les 98 variables conjointement tout en gérant les groupes de variables redondantes, là où les MCO produiraient des coefficients instables.

B. Les variables retenues

Le tableau suivant donne la signification économique des variables retenues par au moins une méthode de sélection ; il facilite la lecture du tableau des coefficients qui suit.

Variables	Signification
IOS	Index of Services : production totale des services
IOS_45	Services, section 45 : commerce et réparation de véhicules automobiles et de motocycles
IOS_G	Services, section G : commerce de gros, de détail et automobile (regroupe les sections 45, 46 et 47)
IOS_47	Services, section 47 : commerce de détail (hors automobile)
IOS_PNDS	Services privés hors distribution (sections H à N et R à U)
RSI	Indice des ventes au détail en volume (tous détaillants, carburant inclus)

IMP_ALL	Importations totales (biens et services), en volume
EXP_MACH	Exportations de machines et matériel de transport, en volume
TOT_LENDING_APP	Nombre d'accords de prêts garantis (immobiliers) aux ménages (Banque d'Angleterre)
CLI	Indicateur composite avancé de l'OCDE

C. Tableau des coefficients

Variables	*MCO*	*Ridge*	*Lasso*	*Elastic-Net (fixed 0.5)*	*Elastic-Net (gridesearch)*	*aLasso (poids Ridge)*	*aLasso (poids Lasso)*	*SCAD*
IOS	1.613*	0.035	0.217	0.118	0.201	0.200	0.192	0.604
IOS_45	0.945***	0.044	0.332	0.196	0.307	0.409	0.452	
IOS_G	-1.473***	0.037	0.013	0.081	0.038			
TOT_LENDING_APP	0.214**	0.030	0.005	0.037	0.021			
IMP_ALL	-0.084	0.025	0.028	0.042	0.038			
EXP_MACH	-0.013	0.025	0.002	0.021	0.011			
IOS_47	0.406**	0.033		0.038	0.009			
CLI	0.107	0.035		0.054	0.006			
IOS_PNDS	-0.768	0.033		0.044				
RSI	0.026	0.031		0.006				
GBP_BROAD	0.454**	0.013						
IOS_46	0.445**	0.023						
BGS_10yrs_yld	0.415**	-0.008						
RPI_ALL	-0.401**	-0.005						
TOT_WEEK_HRS	0.387	0.013						
BGS_5yrs_yld	-0.385***	-0.007						
EXP_TOT	0.367**	0.018						
IOS_EDUC	-0.365	0.023						
EMP_ACT	-0.348**	0.003						
AVG_WEEK_HRS	-0.329	0.012						
CPI_GOOD	0.292**	0.006						
IMP_GOOD	0.263	0.023						
CPI_ALL	-0.259*	-0.006						
AVG_WEEK_RETAIL_SALE_NON_FOOD	-0.230	0.031						
CLAIMS	0.218	-0.010						
EXP_GOOD	-0.206	0.014						
GBP_EUR	-0.203	0.011						
TOT_HOUSE_APP	-0.197	0.026						
EMP	0.175	0.003						
MORT_FIXED_RATE_2YRS	0.172*	0.009						
BGS_20yrs_yld	-0.166	-0.010						
VAC_MANU	-0.159***	-0.008						
AVG_WEEK_RETAIL_SALE	0.157	0.030						
RPI_SERV	0.153	-0.004						
AVG_WEEK_HRS_FULL	-0.150	0.011						
VAC_TOT	0.139	0.003						
CPIH_ALL	0.131	0.002						
EMP_ACT_RATE	0.129	0.008						
GBP_US	-0.123	0.009						
UNEMP_DURA_24mth.	0.122**	0.012						
AWE_ALL	0.115*	0.008						
SONIA	0.100*	0.014						
FTSE_ALL	0.095	0.002						
IMP_FUEL	-0.093	0.001						
M3	0.090	-0.001						
IMP_OIL	0.087	0.003						
UNEMP_DURA_6mth	0.079	0.003						
PPI_MANU	-0.078	-0.005						
UNEMP_RATE	0.076	0.008						
EXP_FUEL	-0.076	-0.001						
CLAIMS_RATE	-0.075	-0.004						
M4	-0.074	-0.004						
IMP_MACH	-0.073	0.022						
PPI_MACH	0.072	0.002						
EMP_RATE	0.067	0.003						
EXP_CRUDE_MAT	0.064	0.016						
CONS_CREDIT_ex_student_loan	0.062	0.013						
MORT_FIXED_RATE_5YRS	-0.056	0.003						
CPI_TRANS	0.054	-0.004						
EXP_OIL	0.050	0.004						
RPI_GOOD	0.046	0.000						
CCI	-0.045	0.002						
CPI_EX_ENER	0.045	-0.004						
IMP_METAL	-0.044	0.001						
EUR_UNC_INDEX	-0.043	-0.008						

RPI_HOUSE	0.043	-0.003
GBP_CAN	-0.042	0.005
M1	-0.042	-0.004
CPI_CLOTH	-0.042	0.001
IMP_CRUDE_MAT	0.041	0.003
FTSE250	-0.037	0.001
CPI_DUR	-0.036	-0.009
OIL_PRICE	0.036	0.021
BANK_RATE	0.035	0.008
AWE_CONS	0.033	0.018
PPI_MOTOR	-0.031	-0.012
SP500	-0.029	0.001
RETAIL_TRADE_INDEX	-0.028	0.028
EMP_PART	-0.026	0.002
UNEMP_DURA_12mth.	-0.023	0.003
AWE_MANU	0.023	0.018
PPI_METAL	-0.021	-0.008
CAR_REGIS	-0.021	0.034
VAC_CONS	0.021	0.013
BCI	-0.020	0.000
GBP_JAP	-0.018	0.004
AWE_PUB	0.015	0.003
UNEMP_DURA_6.12mth	-0.015	0.010
EXP_METAL	0.013	0.014
PPI_OIL	-0.013	0.006
AWE_SERV	-0.012	0.007
CPI_SERV	-0.012	-0.003
VIX	0.006	-0.004
M2	-0.004	-0.004
AWE_PRIV	0.004	0.014
CPI_NON_DUR	-0.004	-0.006
UK_focused_equity	0.003	-0.001
EMP_TEMP	-0.003	-0.005

Source : Auteurs à partir des données de la base balanced_uk_md sous R

Le tableau des coefficients estimés complète la comparaison. Quatre constats s'en dégagent.

- **Un noyau de deux variables très robustes.**

IOS, l'indice de production des services, est retenu par les sept méthodes de sélection ; IOS_45, la production du commerce et de la réparation de véhicules, par six (toutes sauf le SCAD). Ce sont les deux variables des adaptive Lasso et les deux plus gros coefficients du Lasso et des Elastic-Net. Leur lien avec la production industrielle est celui du cycle économique commun : services et industrie évoluent dans le même sens et au même moment, comme l'a montré la crise du Covid, et le commerce automobile dépend directement de la production de véhicules. Ce sont des indicateurs coïncidents de l'activité : ils décrivent le même cycle que la production industrielle, sans en être la cause.

- **Des sélections emboîtées.**

Les ensembles retenus s'emboîtent du plus sévère au moins sévère : le SCAD garde IOS ; les adaptive Lasso y ajoutent IOS_45 ; le Lasso ajoute IOS_G, TOT_LENDING_APP, IMP_ALL et EXP_MACH ; l'Elastic-Net par grid search ajoute IOS_47 et CLI ; l'Elastic-Net à $\alpha = 0{,}5$ ajoute IOS_PNDS et RSI. Chaque méthode moins sévère ajoute des variables sans jamais en retirer : les méthodes ne se contredisent pas, elles diffèrent seulement par le nombre de variables secondaires acceptées. Tous les coefficients retenus sont positifs, cohérent avec des indicateurs d'activité qui évoluent avec la production industrielle.

- **Les MCO sont faussés par la colinéarité.**

Les coefficients MCO sont beaucoup plus grands que ceux des méthodes pénalisées : 1,61 pour IOS contre environ 0,2 pour le Lasso. Aussi, ils présentent des changements de signe entre variables imbriquées par construction : IOS_G agrège les sections 45, 46 et 47 et fait partie de l'indice IOS, tout comme IOS_PNDS. Les MCO compensent alors un effet par un autre : IOS reçoit +1,61, mais IOS_G −1,47 et IOS_PNDS −0,77. Le même phénomène apparaît pour les taux d'intérêt (+0,42 à 10 ans, −0,39 à 5 ans) et pour les prix (+0,29 pour l'inflation des biens, −0,40 pour le RPI). Ces signes opposés n'ont pas de sens économique. Les méthodes pénalisées donnent des coefficients tous positifs et de taille raisonnable.

- **La significativité MCO n'est pas un bon critère de sélection.**

Plusieurs variables significatives en MCO ne sont retenues par aucune méthode telles que le taux de change effectif de la livre (GBP_BROAD), le commerce de gros (IOS_46), les taux obligataires (BGS_5yrs_yld, BGS_10yrs_yld), les prix (RPI_ALL, CPI_GOOD), la population active (EMP_ACT) ou les offres d'emploi industrielles (VAC_MANU). Leur significativité vient de la colinéarité, pas d'un pouvoir explicatif propre. Les variables nominales et financières (prix, taux, marchés actions, agrégats monétaires) sont absentes de toutes les sélections : les variations mensuelles de la production industrielle sont liées aux autres indicateurs d'activité réelle, services, commerce, échanges et crédit, et non aux variables financières.

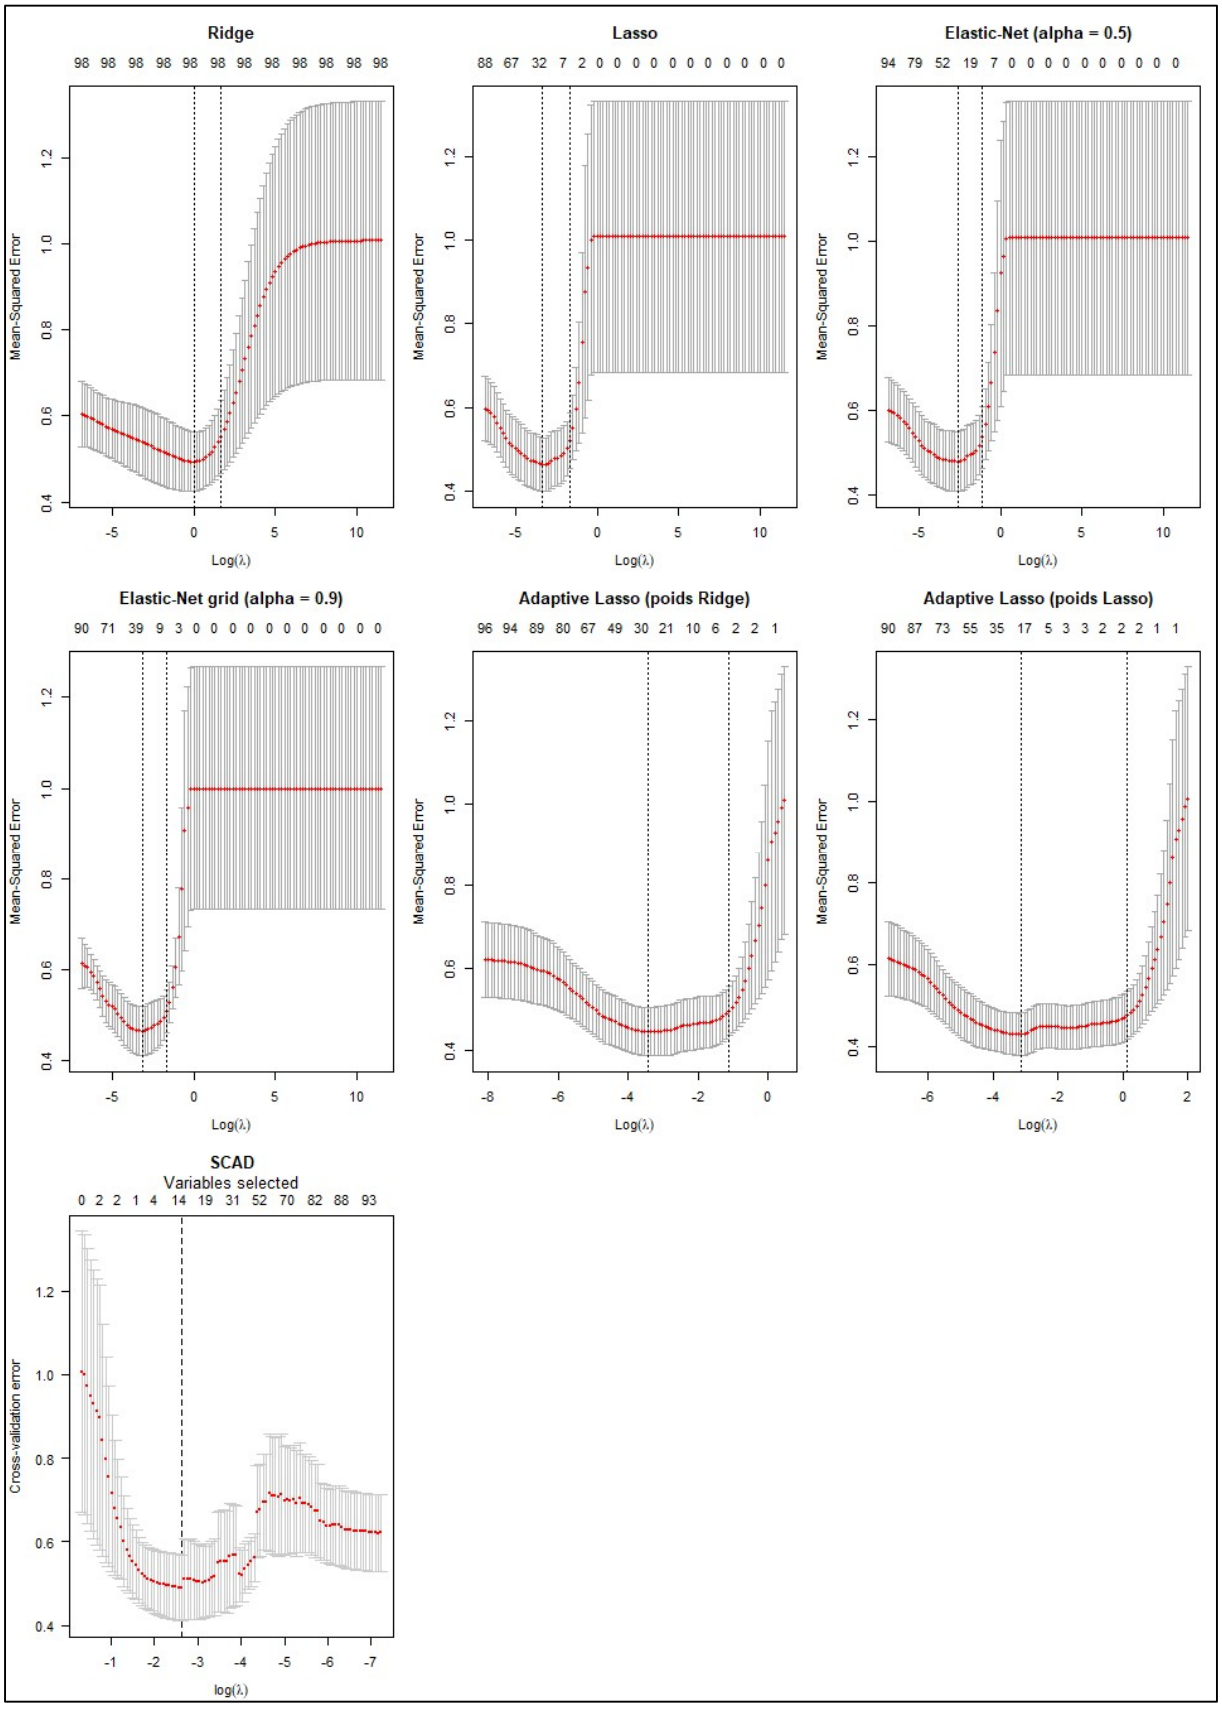
IV. Conclusion

L'analyse exploratoire a d'abord confirmé que la variable à expliquer est stationnaire et non saisonnière, sans qu'aucune transformation supplémentaire ne soit nécessaire, et que la base ne comporte plus de valeurs manquantes après traitement. Elle a surtout mis en évidence une quasi-colinéarité généralisée entre les 98 variables explicatives. Celle-ci rend les estimations MCO instables et leurs coefficients inexploitables, comme le montrent des changements de signe sans signification économique et la significativité trompeuse de plusieurs variables.

Face à ce diagnostic, les régressions pénalisées ont permis à la fois de stabiliser l'estimation et de sélectionner les variables. Les adaptive Lasso se sont imposés sur les deux plans : ils obtiennent la meilleure performance hors échantillon (erreur de validation croisée de 0,476) et réduisent les 98 variables candidates à deux, IOS et IOS_45. Ce noyau est retenu par presque toutes les méthodes et ne dépend pas des poids utilisés à la première étape. Le meilleur modèle explicatif de la production industrielle britannique tient ainsi en deux indicateurs coïncidents du cycle, la production des services et le commerce automobile, tandis que les variables nominales et financières, pourtant nombreuses dans la base, n'apportent pas d'information supplémentaire.

Ces résultats restent à nuancer. Les variables étant observées au même mois que la production industrielle, ils décrivent un cycle commun sans permettre de prévoir ni de conclure à une causalité. La période du Covid pèse aussi fortement sur les estimations. Introduire des variables retardées et une validation croisée respectant l'ordre temporel permettrait de passer de l'explication à la prévision.

Annexe


Ridge
98 98 98 98 98 98 98 98 98 98 98 98
Lasso
88 67 32 7 2 0 0 0 0 0 0 0 0 0 0 0
Elastic-Net (alpha = 0.5)
94 79 52 19 7 0 0 0 0 0 0 0 0 0 0 0
Elastic-Net grid (alpha = 0.9)
90 71 39 9 3 0 0 0 0 0 0 0 0 0 0 0
Adaptive Lasso (poids Ridge)
96 94 89 80 67 49 30 21 10 6 2 2 1
Adaptive Lasso (poids Lasso)
90 87 73 55 35 17 5 3 3 2 2 2 1 1
SCAD
Variables selected
0 2 2 1 4 14 19 31 52 70 82 88 93
Mean-Squared Error
Cross-validation error
Log(λ)
log(λ)